



南開大學
Nankai University

计算机学院
自然语言处理

作业一文本分类

词袋模型、词向量与 BERT 的比较

姓名：崔迪

学号：2412439

专业：计算机科学与技术

2026 年 9 月 25 日

目录

1	实验目标与数据划分	1
1.1	数据与固定随机划分	1
1.2	评价指标与防止信息泄漏	1
2	词袋表示与逻辑回归	2
2.1	文本预处理与表示	2
2.2	分类器与验证集选参	2
3	词向量与文档均值表示	3
3.1	三种词向量来源	3
3.2	文档池化与分类	3
4	BERT 全参数微调	4
4.1	模型与训练设置	4
5	统一测试结果与比较	5
6	错误分析与重复文本核查	6
6.1	排除训练集重叠文本后的核查	6
7	复现说明与实验结论	7
7.1	运行环境与代码组织	7
7.2	正确性检查与局限	7
7.3	实验结论	7

1 实验目标与数据划分

本实验比较七种文本分类方案：三种词袋表示、三种均值词向量表示，以及 BERT 全参数微调。前六种方案统一使用 Logistic Regression (LR)，以区分文本表示对分类的影响；所有方案最终在同一 NYT 测试集上评价。本文同时报告 Accuracy 与 Macro-F1，并使用验证集选取参数或模型轮次。

1.1 数据与固定随机划分

课程提供 NYT 新闻 11,519 条，标签为 business、politics、sports；AG News 共 90,000 条，仅含 text 列，用于独立训练 Word2Vec。NYT 原始文本没有空记录或未知标签。保留原始 CSV 内容，以原始行号建立划分。

作业给出了 80%/10%/10% 的划分比例，但“请统一设置”之后未显示种子值，因此实现固定 seed=42。使用 NumPy 的 `RandomState(42).permutation(N)` 打乱索引，在 $[0.8N]$ 与 $[0.9N]$ 处分段，不进行分层采样。

表 1: NYT 数据划分及类别数量

划分	business	politics	sports	合计
训练集	1157	1134	6924	9215
验证集	124	152	876	1152
测试集	148	165	839	1152
全部	1429	1451	8639	11519

体育新闻占总数据的 75.0%。测试集类别比例受随机划分影响略有变化，因此仅看 Accuracy 容易高估多数类预测器。始终预测训练集多数类 sports 的基线，其测试 Accuracy 为 72.83%，Macro-F1 仅为 28.09%。

1.2 评价指标与防止信息泄漏

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(\hat{y}_i = y_i), \quad \text{Macro-F1} = \frac{1}{3} \sum_{c=1}^3 \frac{2P_c R_c}{P_c + R_c}.$$

当分母为零时，对应指标按零处理。词表、IDF、特征标准化参数和 NYT Word2Vec 只在训练集拟合；验证集用于选参，测试集不参与参数选择。原始数据含 72 条重复文本记录，划分后训练/验证有 12 个相同文本、训练/测试有 8 个相同文本。主实验保持指定的随机划分，后文另外报告排除训练集重叠文本后的敏感性核查。

2 词袋表示与逻辑回归

2.1 文本预处理与表示

将文本转为小写，正则表达式 $[a-z]+(?:'[a-z]+)?$ 提取英文单词，保留单词内部的撇号；不保留数字和标点，不去停用词，不做词干化。所有传统方法采用相同规则。训练集上用 `min_df=2` 过滤只出现于一篇文档的词，得到 41,589 维稀疏词表。验证和测试中未入词表的词直接忽略。

对于第 j 个词在文档 d 中的出现次数 $c_{d,j}$ ，三种表示为

$$x_{d,j}^{\text{bin}} = \mathbb{I}(c_{d,j} > 0), \quad x_{d,j}^{\text{count}} = c_{d,j}, \quad \tilde{x}_{d,j}^{\text{tfidf}} = c_{d,j} \left[\log \frac{1 + N_{\text{train}}}{1 + \text{df}_j} + 1 \right].$$

TF-IDF 再按每篇文档做 L_2 归一化；Binary 与原始词频不做额外归一化。作业说明要求三种词袋方法，但正文只列出 Binary 与 Word Frequency，因此第三组补充常用的 TF-IDF，作为词频经逆文档频率加权后的对照。

2.2 分类器与验证集选参

多分类逻辑回归以 $p(y = c \mid x) = \text{softmax}(Wx + b)_c$ 建模，最小化交叉熵与 L_2 正则项。使用 `lbfgs` 求解，最大迭代数 2000，容差 10^{-4} ，不设置类别权重。正则化强度的倒数 C 从 $\{0.01, 0.1, 1, 10\}$ 中选择，按验证集 Macro-F1 最大值确定，同分保留较小 C 。选定后直接评价对应的训练集模型，不将验证集并入训练集。

表 2: 三种词袋模型的验证选参与测试结果

表示	所选 C	验证 Macro-F1	测试 Accuracy	测试 Macro-F1
Binary BoW	0.1	97.09	98.70	97.11
Word Frequency	10.0	97.77	99.22	98.07
TF-IDF	10.0	96.81	99.13	98.03

表中分类指标单位均为百分比。三组模型全部达到设定的 LR 收敛条件。

Binary 表示强调关键词是否出现，避免重复次数直接放大特征；词频保留某个主题词在全文中的重复信息；TF-IDF 抑制通用高频词并缓解文档长度差异。这些设计各有取舍，不能仅从表示形式预先判断哪一种一定最好。测试结果的差异需要结合验证选参、错误数量与类别表现解释。

词袋矩阵始终采用稀疏存储，不转成完整的 9215×41589 稠密数组。这样能保留完整新闻的主题词信息，同时控制内存使用。

3 词向量与文档均值表示

3.1 三种词向量来源

GloVe 使用作业指定的 `glove.6B.100d.txt`，即 Wikipedia 2014 与 Gigaword 5 语料的 100 维公开向量 [1]。使用完整原版文件，下载镜像仅改变传输来源；脚本通过 SHA256 验证文件一致性。加载时仅保留当前 NYT 文本用到的词，这只是减少内存占用，不训练或调整预训练向量。

两组 Word2Vec 分别用全部 AG News 文本和 NYT 训练集文本学习向量。选择 Skip-gram 与 负采样：以中心词预测上下文词，通过正词对和噪声词对学习区分性的局部共现表示。所有参数保持一致，具体见表。NYT 验证与测试文本不用于词向量训练。

表 3: Word2Vec 训练配置

参数	设置	参数	设置
维度	100	窗口	5
架构	Skip-gram	负样本数	5
最小词频	2	高频词采样	10^{-3}
训练轮数	10	工作线程	1
随机种子	42	词哈希	稳定 MD5 派生哈希

3.2 文档池化与分类

令 $K(d)$ 为文档中能查到词向量的 token 出现位置集合，则

$$e(d) = \frac{1}{|K(d)|} \sum_{i \in K(d)} e(w_i), \quad |K(d)| > 0.$$

重复出现的词重复计入平均；OOV 词跳过，整篇文档没有有效向量时置零。随后使用仅在训练集拟合的 StandardScaler 标准化各维度，再使用与词袋实验相同的 LR 参数网格。均值池化的特征维数仅为 100，但会丢失词序，也会将少量关键主题词与大量普通词混合。

表 4: 词向量覆盖率与分类结果

表示	测试 token 覆盖率	所选 C	Accuracy	Macro-F1
GloVe 6B	98.14%	0.1	98.87	97.56
Word2Vec AG	97.11%	0.01	98.35	96.37
Word2Vec NYT	99.21%	0.1	98.96	97.68

AG 与 NYT Word2Vec 的词表大小分别为 36,715 与 45,291。三个方案的测试集全 OOV 文档数依次为 0、0、0。

覆盖率按匹配的 token 出现次数除以全部 token 数计算，不能与词表类型覆盖率混用。覆盖率高表示较少信息因 OOV 丢失，但不能单独保证更高分类性能；语料领域匹配、词向量质量以及均值表示是否保留判别信息同样重要。

4 BERT 全参数微调

4.1 模型与训练设置

使用 `google-bert/bert-base-uncased` 预训练模型 [2]，添加三分类输出层并更新全部参数。使用配套 WordPiece 分词器，大小写归一化由分词器完成；输入设 `max_length=64`，包含特殊 token，不足补齐，超长截断。这个设置严格遵循作业要求，不能与传统方法使用全文的条件完全等同。

表 5: BERT 微调参数

参数	设置	参数	设置
训练轮数	3	最大长度	64
训练批大小	32	评价批大小	64
优化器	AdamW	学习率	2×10^{-5}
权重衰减	0.01	梯度裁剪	1.0
学习率计划	线性衰减	预热比例	10%
精度	float32	训练设备	Apple M5 MPS

偏置和 LayerNorm 权重不施加权重衰减。每轮训练 288 个批次，共 864 个优化步骤。固定 Python、NumPy 和 PyTorch 随机种子，训练 DataLoader 也使用固定生成器。每轮结束后计算验证集指标，训练完整 3 轮后加载验证集 Macro-F1 最佳的检查点，最终只对该检查点评价测试集。

表 6: BERT 三轮训练轨迹

Epoch	训练损失	验证 Accuracy	验证 Macro-F1
1	0.2763	97.14	92.85
2	0.0483	96.96	93.16
3	0.0177	97.31	93.66




图 1: BERT 的训练损失与验证集 Macro-F1

验证集选中的检查点来自第 3 轮，其测试 Accuracy 为 97.92%，Macro-F1 为 95.30%。测试文本中 100.00% 的原始 WordPiece 序列超过 64 个 token，存在截断。因而模型主要依赖文章开头的信息；损失持续下降也不必然意味着验证集表现持续提高。

5 统一测试结果与比较

表 7: 七组方法在同一 NYT 测试集上的结果

方法	Accuracy (%)	Macro-F1 (%)	错误数 / 1152
Binary BoW	98.70	97.11	15
Word Frequency	99.22	98.07	9
TF-IDF	99.13	98.03	10
GloVe 6B	98.87	97.56	13
Word2Vec AG	98.35	96.37	19
Word2Vec NYT	98.96	97.68	12
BERT	97.92	95.30	24




图 2: 统一测试集上的 Accuracy 与 Macro-F1

本次实验中，Word Frequency 的测试 Macro-F1 最高，为 98.07%。词频模型正确分类 1,143 条新闻，仅有 9 条错误；Binary、TF-IDF 的错误数分别为 15 和 10。这些结果说明当前新闻类别具有较强的词汇主题信号，线性模型即可取得较高性能。

静态均值词向量压缩了输入，但没有直接保存某个类别关键词的独立坐标。BERT 具备上下文建模能力，同时受到 64 token 输入预算和当前训练设置的约束。因此，本实验衡量的是指定数据、划分和参数下各完整方案的表现，不能据此断言某一表示方法在所有任务上优于另一种。

6 错误分析与重复文本核查




图 3: 词频、NYT Word2Vec 与 BERT 的混淆矩阵。数字为样本数，颜色按真实类别行归一化。

表 8: 各类别测试 F1 分数

方法	business	politics	sports
Word Frequency	96.89	97.33	100.00
GloVe 6B	96.27	96.66	99.76
Word2Vec AG	94.52	94.89	99.70
Word2Vec NYT	96.22	97.01	99.82
BERT	92.83	93.37	99.70

词频模型的 9 个错误全部发生在 business 与 politics 之间，其中 8 条商业新闻被判为政治、1 条政治新闻被判为商业；839 条体育新闻均正确。BERT 的体育类错误为 2 条，总错误为 24 条。宏平均 F1 对商业和政治类别等权计算，因此更容易暴露多数类 Accuracy 所掩盖的差异。

例如，原始行号 11451 的新闻讨论星巴克小费分配的劳动法裁决，标签为 business，但法院与法律措辞使其被词频模型判为 politics；行号 5854 的政治新闻讨论食品补助削减对家庭预算的影响，却被判为 business。两例均存在跨领域词汇，显示类别边界本身具有语义重叠。行号按 CSV 数据行从零计数。

6.1 排除训练集重叠文本后的核查

将测试集中全文与任意训练文本完全相同的记录排除，仅重新计算既有预测的指标，不重新训练、不调整参数，也不据此选择模型。这一核查用于观察精确重复对当前结果的影响，不能替代专门设计的去重后重新划分实验。

表 9: 排除训练集同文测试记录后的结果

方法	保留样本数	Accuracy (%)	Macro-F1 (%)
Word Frequency	1144	99.21	98.04
Word2Vec NYT	1144	98.95	97.65
BERT	1144	97.90	95.23

7 复现说明与实验结论

7.1 运行环境与代码组织

本次运行使用 Python 3.12.14、NumPy 2.2.6、SciPy 1.16.3、scikit-learn 1.7.2、Gensim 4.4.0、PyTorch 2.14.0 与 Transformers 4.57.6；本机为 Apple M5，24 GiB 统一内存。Gensim 的 BLAS 点积指针声明做了最小修复，将合法的 -1 返回值从异常判定中移除；修复脚本随代码提供，正式 Word2Vec 结果均在修复后重跑。完整版本保存在 requirements-lock.txt。训练过程保留随机划分、每组超参数、验证轨迹、完整测试指标与逐样本预测，结果图直接由 JSON 生成。

```
python -m pip install -r HW-1/requirements.txt
python HW-1/code/fix_gensim_blas.py
python HW-1/code/download_assets.py
PYTHONHASHSEED=42 TOKENIZERS_PARALLELISM=false \
  python HW-1/code/experiment.py --task all
python HW-1/code/plot_results.py
python HW-1/code/audit_results.py
```

数据索引与文件哈希位于 results/split.json；代码拒绝在既有目录中覆盖不同种子或不同原始数据的划分。可用 --task 单独运行某组实验，用 --device 选择 CPU、MPS 或 CUDA。不同设备的浮点运算可能引入小幅差异，固定种子并不等于保证逐位相同。

7.2 正确性检查与局限

自动检查覆盖划分不相交且无遗漏、固定种子复现、测试独有词不进入训练词表、重复 token 的均值池化、全 OOV 处理与 Macro-F1 计算。全部模型的保存指标还由逐样本预测重新计算核对。代码对非有限特征、非有限权重和 LR 未收敛情况报错。

本实验只使用一个随机种子，未估计不同划分和重复训练的置信区间；BERT 使用文本前 64 个 token，其余方法使用全文；数据还可能存在未检出的近重复新闻。主测试结果中的微小差距不应被解释为统计显著优势。进一步实验可采用去重后分组划分、多种子重复评价、BERT 输入长度消融，以及在保持分类器一致的前提下比较加权池化。

7.3 实验结论

七组方案均在同一测试集完成评价。当前结果中 Word Frequency 的 Macro-F1 最高；三类新闻的主题词足以支持强线性基线。词向量均值表示将维度降至 100，但压缩过程会混合主题信息；BERT 的上下文优势需要结合输入长度、训练预算和领域条件理解。实验中最关键的控制是共享数据划分、仅用训练集拟合表示、按验证集选模，以及用分类别指标与 Macro-F1 解释不平衡数据上的表现。

参考文献

- [1] Pennington, J., Socher, R., Manning, C. D. GloVe: Global Vectors for Word Representation. EMNLP, 2014. <https://nlp.stanford.edu/projects/glove/>
- [2] Devlin, J., Chang, M.-W., Lee, K., Toutanova, K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL, 2019. 模型: <https://huggingface.co/google-bert/bert-base-uncased>